

**ESCUELA COLOMBIANA DE INGENIERÍA
JULIO GARAVITO**

MEDIFINDER

Búsqueda Inteligente de Medicamentos

Proyecto Final de la materia
Principios y Tecnologías de Inteligencia Artificial

Autores:

Mariana Malagón Tochoy
Ignacio Andrés Castillo Rendón

Profesor: Jossie Esteban Murcia Triviño

Universidad Escuela Colombiana de Ingeniería Julio Garavito
Facultad de Ingeniería de Sistemas

2026-1

Declaración firmada

”Declaro que he escrito este trabajo de investigación por mí mismo, y que no he utilizado otras fuentes o recursos que los indicados para su preparación. Declaro que he indicado claramente todas las citas directas e indirectas, y que este documento no se ha presentado en otro lugar para fines de examen o publicación”

Nombre del estudiante & Firma:



Mariana Malagón Tochoy

Fecha: 17 de febrero de 2026



Ignacio Andrés Castillo Rendón

Fecha: 17 de febrero de 2026

Índice de contenido

1	Introducción	7
1.1	Problemas identificados	7
1.1.1	Problema 1: Desabastecimiento de medicamentos y falta de alternativas	7
1.1.2	Problema 2: Ineficiencia en la gestión de inventarios farmacéuticos	7
1.1.3	Problema 3: Asimetría de información entre pacientes y el sistema de salud	7
1.2	Justificación como proyecto de Principios y Tecnologías de Inteligencia Artificial	8
1.3	Contexto de la crisis del sistema de salud colombiano	8
2	Trabajos Relacionados	10
2.1	Clasificación de medicamentos mediante visión por computadora	10
2.1.1	Trabajo 1: Drug Identification System usando CNN	10
2.1.2	Trabajo 2: Pill Recognition usando ResNet-50	10
2.2	Sistemas de recomendación farmacéuticos	11
2.2.1	Trabajo 3: Drug Recommendation usando Sentiment Analysis	11
2.2.2	Trabajo 4: Content-Based Drug Recommendation	11
2.3	Diferenciación del proyecto MediFinder	12
3	Descripción y caracterización detallada del problema	13
3.1	Criterios y proceso de selección del problema	13
3.1.1	Comparación entre los problemas identificados	13
3.2	Caracterización detallada del problema seleccionado	14
4	Objetivos	17
4.1	Objetivo general	17
4.2	Objetivos específicos	17
5	Marco Teórico	18
5.1	EPS e IPS	18
5.2	Deuda de las EPS	18
5.3	Reconocimiento Óptico de Caracteres (OCR)	19
5.4	Redes Neuronales Convolucionales (CNN)	20
5.5	K-Nearest Neighbors (KNN)	20
6	Propuesta de solución	22
6.1	Prototipo de papel	22
6.2	Prototipo de interfaz	23
6.3	Arquitectura del sistema (MVP)	25
6.3.1	Paso 1: Captura de imagen y preprocesamiento	26
6.3.2	Paso 2: Extracción y verificación de texto (OCR + normalización)	26

6.3.3	Paso 3: Consulta de información y recomendación de alternativas (KNN)	26
6.4	Fuentes de datos (Colombia) e integración	27
7	Enfoque metodológico y técnico	28
7.1	Decisiones metodológicas (por qué este enfoque)	28
7.2	Pipeline técnico del MVP	28
7.2.1	Módulo 1: Ingesta de imagen	28
7.2.2	Módulo 2: OCR + normalización + mapeo a medicamento	28
7.2.3	Módulo 3: Enriquecimiento + recomendaciones por principio activo (KNN)	29
7.3	Evaluación (qué se medirá)	29
7.4	Extensión prevista (CNN como respaldo)	29
8	Evaluación	31
8.1	Casos de falla	31
9	Reflexiones	49
9.1	Lecciones aprendidas	49
9.2	Conclusiones y trabajo futuro	53

Índice de Tablas

Índice de figuras

1	Detalle del gasto en salud por categorías 2021-2025	15
2	Evolución del gasto privado en medicamentos en Colombia 2021-2025	15
3	Prototipo de papel (wireframe) del MVP de MediFinder: captura/subida, extracción y verificación (OCR) y resultados con función del medicamento y alternativas (KNN por principio activo).	22
4	Pantalla 1 del prototipo de interfaz de MediFinder.	23
5	Pantalla 2 del prototipo de interfaz de MediFinder.	24
6	Pantalla 3 del prototipo de interfaz de MediFinder.	25
7	Falla de identificación para Naproxeno Sódico 275 mg. El ángulo oblicuo de captura y la presencia de la mano en el encuadre impiden tanto el OCR como la búsqueda visual CNN. El sistema presenta campos vacíos y guía al usuario hacia la entrada manual.	32
8	Falla de identificación para Omeprazol con caja sostenida lateralmente. La orientación de la imagen expone la cara lateral del empaque en lugar de la frontal, impidiendo tanto el OCR como la búsqueda visual CNN.	34
9	Pantalla de verificación para Acetaminofén 500 mg. OCR con 99 % de confianza y <i>match</i> de catálogo al 99 %.	36

10	Pantalla de resultados: medicamento identificado, 1 alternativa encontrada con similitud 100 % y sección expandible de información del principio activo.	37
11	Explicación del principio activo paracetamol (acetaminofén) generada por Claude Haiku con RAG, presentada en seis secciones clínicas estructuradas y contextualizadas para el paciente colombiano.	38
12	Pantalla de verificación para Doxiciclina 100 mg. OCR y <i>match</i> de catálogo al 99 %, campos prepopulados correctamente sin intervención del usuario. . .	40
13	Pantalla de resultados para Doxiciclina 100 mg. El KNN identifica correctamente 1 alternativa con similitud 100 %; sin embargo, la sección de información del principio activo muestra una explicación sobre <i>doxazosina</i> en lugar de <i>doxiciclina</i> , evidenciando una falla en la recuperación RAG por similitud léxica espuria.	41
14	Pantalla de verificación para Cefalexina 500 mg. OCR y <i>match</i> de catálogo al 99 %, con registro INVIMA M-006738-R1.	43
15	Pantalla de resultados para Cefalexina 500 mg. Cinco alternativas únicas de nivel 1 con similitud 100 %, diferenciadas por forma farmacéutica y titular. .	44
16	Pantalla de verificación para Aspirina 500 mg. OCR y <i>match</i> de catálogo al 99 %, con identificación correcta del principio activo ácido acetilsalicílico. .	46
17	Pantalla de resultados para Aspirina 500 mg. El LLM detecta y reporta activamente la confusión semántica en la recuperación RAG, a diferencia del Caso 4 donde la explicación incorrecta se presentó sin advertencia.	47

Resumen

Colombia enfrenta una crisis crítica en el sector salud derivada de la deuda acumulada de aproximadamente 32.9 billones de pesos entre 29 Entidades Promotoras de Salud (EPS), según informes del Ministerio de Salud emitidos en julio de 2025. Esta problemática financiera ha desencadenado graves consecuencias para las Instituciones Prestadoras de Servicios de Salud (IPS), generando desabastecimiento de medicamentos, demoras extensas en la entrega de fármacos y barreras de acceso para pacientes que dependen de tratamientos continuos. La Corte Constitucional ha constatado que persisten dificultades en la entrega de medicamentos por deudas acumuladas, incremento de tutelas y ausencia de información confiable para alertar sobre desabastecimientos.

Ante esta situación, el presente trabajo propone el desarrollo de un prototipo de inteligencia artificial que brinde una solución temporal mientras se implementan reformas estructurales al sistema de salud. La propuesta consiste en un sistema que utiliza **Reconocimiento Óptico de Caracteres (OCR)** para extraer el nombre del medicamento desde una fotografía (caja o parte trasera del blíster), valida el resultado mediante verificación del usuario y consulta fuentes colombianas para enriquecer la información del producto. Posteriormente, el sistema recomienda **alternativas farmacéuticas** priorizando equivalencias por **principio activo principal**, empleando un enfoque de similitud basado en **K-Nearest Neighbors (KNN)** y reglas de filtrado.

El MVP implementa un pipeline automatizado que, a partir de la imagen del medicamento, obtiene el texto relevante, identifica el fármaco, presenta su **función** (tipo terapéutico y usos generales) y sugiere alternativas disponibles en el catálogo, priorizando medicamentos con la misma molécula y, de manera secundaria e informativa, opciones de la misma clase terapéutica cuando no existan equivalentes suficientes. Este enfoque busca empoderar a los pacientes con información oportuna mientras se resuelven los problemas estructurales del sistema de salud colombiano, mitigando el impacto de la crisis sobre personas con enfermedades crónicas o tratamientos de alto costo.

Palabras clave

Medicamentos, EPS, IPS, OCR, KNN, Búsqueda por similitud, Recomendación, Principio activo, Machine Learning

Abstract

Colombia faces a critical crisis in the health sector derived from the accumulated debt of approximately 32.9 trillion pesos among 29 Health Promoting Entities (EPS), according to reports from the Ministry of Health issued in July 2025. This financial problem has triggered severe consequences for Health Service Provider Institutions (IPS), generating medicine shortages, extensive delays in drug delivery, and access barriers for patients who depend on continuous treatments. The Constitutional Court has confirmed that difficulties persist in medicine delivery due to accumulated debts, increased legal actions, and absence of reliable information to alert about shortages.

In response, this work proposes an artificial intelligence MVP that provides a temporary, user-oriented solution while structural reforms are implemented. The proposed system applies **Optical Character Recognition (OCR)** to extract the medicine name from a photograph (medicine box or the back side of a blister pack), validates the extracted text through user verification, and queries Colombian data sources to enrich the drug profile. It then recommends **pharmaceutical alternatives** by prioritizing equivalence through the **main active ingredient**, using a similarity-based ranking strategy with **K-Nearest Neighbors (KNN)** and filtering rules.

The MVP implements an automated pipeline that extracts relevant text from the image, identifies the drug, displays its **function** (therapeutic type and general uses), and suggests alternatives available in the catalog, prioritizing same-molecule options and, secondarily (as informational suggestions), same-therapeutic-class alternatives when direct equivalents are not available. This approach aims to empower patients with timely information while mitigating the crisis impact on people with chronic conditions or high-cost treatments.

Key words

Medicines, EPS, IPS, OCR, KNN, Similarity search, Recommendation, Active ingredient, Machine Learning

1. Introducción

1.1. Problemas identificados

Ante la crisis estructural del sistema de salud colombiano, se identificaron tres problemas principales que podrían beneficiarse de soluciones tecnológicas basadas en inteligencia artificial:

1.1.1. Problema 1: Desabastecimiento de medicamentos y falta de alternativas

Los pacientes enfrentan largas esperas y frecuentemente no encuentran los medicamentos prescritos en las farmacias. La falta de información sobre alternativas farmacéuticas con componentes activos similares genera frustración, abandono de tratamientos y deterioro de la salud, especialmente en personas con enfermedades crónicas.

1.1.2. Problema 2: Ineficiencia en la gestión de inventarios farmacéuticos

Las farmacias y gestores farmacéuticos carecen de sistemas predictivos que permitan anticipar desabastecimientos y optimizar la distribución de medicamentos. La falta de visibilidad en tiempo real sobre la disponibilidad de fármacos en diferentes puntos de la cadena de suministro genera pérdidas económicas y afecta la atención al paciente.

1.1.3. Problema 3: Asimetría de información entre pacientes y el sistema de salud

Los pacientes tienen acceso limitado a información confiable sobre sus medicamentos, alternativas disponibles, precios comparativos y disponibilidad en diferentes farmacias. Esta brecha informativa los deja en desventaja frente a un sistema de salud complejo y en crisis.

1.2. Justificación como proyecto de Principios y Tecnologías de Inteligencia Artificial

De los tres problemas identificados, se seleccionó el **Problema 1: Desabastecimiento de medicamentos y falta de alternativas** porque es ideal para un proyecto de PTIA por las siguientes razones:

- **Requiere visión por computadora:** La identificación de medicamentos a partir de fotografías es un problema clásico de clasificación de imágenes que se beneficia de Redes Neuronales Convolucionales (CNN).
- **Involucra sistemas de recomendación:** Encontrar medicamentos similares basándose en componentes activos y características extraídas requiere algoritmos de aprendizaje automático como K-Nearest Neighbors (KNN).
- **Combina múltiples técnicas de IA:** El proyecto integra deep learning (CNN para clasificación) con machine learning tradicional (KNN para recomendación), permitiendo explorar diferentes enfoques y compararlos.
- **Permite aprendizaje supervisado:** Se puede entrenar el modelo con un dataset etiquetado de medicamentos, aplicando técnicas de data augmentation, transfer learning y fine-tuning.
- **Tiene métricas evaluables:** Es posible medir el desempeño del sistema con métricas estándar como accuracy, precision, recall y F1-score para clasificación, y métricas de similitud para recomendación.
- **Escalabilidad y mejora continua:** El modelo puede mejorarse continuamente con más datos, explorando arquitecturas más avanzadas como ResNet, EfficientNet o Vision Transformers.

1.3. Contexto de la crisis del sistema de salud colombiano

En los últimos años se ha venido presentando una problemática país con respecto al sector de salud, específicamente hacia el sector de las EPS (Entidad Promotora de Salud), en donde hace dos años el presidente vigente Gustavo Petro denunció reportes fraudulentos sobre la distribución de sus recursos para la atención en salud y fue el año pasado que, según informes presentados por el Ministerio de Salud el 15 de Julio del 2025, comenta que esa deuda (en el cual reúne al menos 29 EPS) es de aproximadamente 35 billones de dólares Ministerio de Salud y Protección Social de Colombia, 2025. Esta deuda genera una crisis en el sistema de salud porque el gobierno está acorralando y asfixiando a una posible liquidez de las IPS

(Instituciones Prestadoras de Servicios de Salud), provocando el cierre de servicios, falta de pagos a médicos, desabastecimiento de medicamentos y barreras de acceso para pacientes. La problemática financiera desencadena una serie de conflictos, no solamente en la sostenibilidad de hospitales y clínicas, como demoras y falta de medicamentos.

Bajo esta naciente preocupación, donde aumenta de sobremanera los tiempos de espera para su distribución, afectando la continuidad de los tratamientos, en el último año se han venido haciendo cada vez más evidentes. Acorde a una investigación por parte de la Corte Constitucional, nos demuestra la realidad, la cual no es nada favorable:

“La Corte Constitucional constató que persisten graves dificultades en la entrega de fármacos por deudas acumuladas entre EPS y gestores farmacéuticos, incremento de tutelas de pacientes, retrasos en trámites del Invima y ausencia de información confiable para alertar los desabastecimientos.” Colprensa, 2025

Se han ido proponiendo e implementando estrategias desde que inició el año para mitigar los daños, aparte de los ya presentes, entre ellas que el estado se haga cargo de los recursos de las EPS y que estas ultimas se encarguen solamente de prestar un servicio únicamente de gestores de vida y salud, además de un fuerte aumento en el presupuesto de los recursos destinados al sector salud.

Sin embargo, toda esta problemática sobre el asunto de los medicamentos no es algo que podrá encontrar una solución de manera inmediata porque a pesar de que estalló con la deuda de las EPS, es algo que venía de años atrás. Aún así, la sociedad colombiana no se puede quedar esperando por una respuesta positiva por parte de las entidades de salud tanto tiempo, porque la brecha que irá dejando a su paso será inmensa.

No es un tema sencillo de resolver, pero en unión con las innovaciones y revoluciones utilizando la tecnología como medio, se puede encontrar aquel punto óptimo, así mientras se termina de dar el camino más adecuado para el sector salud en Colombia, la sociedad colombiana no termine siendo los más afectados ante todo este conflicto.

2. Trabajos Relacionados

Esta sección presenta una revisión de trabajos previos relacionados con la clasificación de medicamentos mediante inteligencia artificial y sistemas de recomendación farmacéuticos.

2.1. Clasificación de medicamentos mediante visión por computadora

2.1.1. Trabajo 1: Drug Identification System usando CNN

Kumar et al. (2019) desarrollaron un sistema de identificación de medicamentos mediante deep learning que utiliza CNN para clasificar píldoras y tabletas a partir de imágenes.

Tecnología utilizada:

- Red Neuronal Convolutacional (CNN) con 6 capas convolucionales
- Transfer learning con ImageNet
- Framework: TensorFlow y Keras

Resultados:

- Accuracy: 94.3 %
- Tiempo de inferencia: 0.8 segundos por imagen

2.1.2. Trabajo 2: Pill Recognition usando ResNet-50

Zeng et al. (2020) utilizaron ResNet-50 con fine-tuning específico para reconocimiento de medicamentos.

Tecnología utilizada:

- ResNet-50 pre-entrenada
- Data augmentation avanzado
- Framework: PyTorch

Resultados:

- Accuracy: 96.7 %

- Top-5 accuracy: 99.1 %

2.2. Sistemas de recomendación farmacéuticos

2.2.1. Trabajo 3: Drug Recommendation usando Sentiment Analysis

Doshi et al. (2021) propusieron un sistema de recomendación basado en análisis de sentimientos y componentes activos.

Tecnología utilizada:

- Natural Language Processing (NLP)
- K-Nearest Neighbors para medicamentos similares
- Filtrado colaborativo

Resultados:

- Precisión en recomendaciones: 87.5 %
- Satisfacción de usuarios: 78 %

2.2.2. Trabajo 4: Content-Based Drug Recommendation

Park et al. (2022) desarrollaron un sistema basado en similitud de componentes activos usando autoencoders.

Tecnología utilizada:

- Autoencoder para embeddings de medicamentos
- Similitud coseno en espacio latente
- Base de datos FDA

Resultados:

- Precisión: 91.2 %
- Recall: 85.7 %

2.3. Diferenciación del proyecto MediFinder

MediFinder integra ambas líneas de investigación:

- Pipeline completo: desde captura de imagen hasta recomendación
- CNN para clasificación + KNN para recomendación
- Contextualizado a Colombia

3. Descripción y caracterización detallada del problema

3.1. Criterios y proceso de selección del problema

A partir de los tres problemas identificados en la Introducción, se realizó un proceso de comparación para seleccionar un problema con alto impacto social, urgencia evidente y viabilidad técnica para un prototipo de IA dentro del tiempo del curso. La selección se basó en los siguientes criterios:

1. **Impacto social medible:** afecta directamente a pacientes (especialmente crónicos) y se refleja en deterioro de continuidad de tratamientos y quejas/tutelas.
2. **Urgencia temporal:** crisis activa que requiere medidas de apoyo en el corto plazo.
3. **Viabilidad técnica con IA (MVP):** posibilidad de construir un flujo completo y evaluable con OCR, KNN y fuentes de datos disponibles.
4. **Disponibilidad de datos:** existencia de fuentes públicas u oficiales para construir un catálogo mínimo (p. ej., INVIMA y MinSalud).
5. **Factibilidad de implementación:** implementación de software realizable en el marco del proyecto académico.
6. **Empoderamiento del usuario:** entrega información práctica directamente al paciente.
7. **Escalabilidad:** capacidad de crecimiento a más medicamentos y más fuentes.

3.1.1. Comparación entre los problemas identificados

- **Problema 1: Desabastecimiento de medicamentos y falta de alternativas.** Presenta impacto directo en la continuidad del tratamiento y permite un MVP con un flujo claro: foto del empaque → identificación por OCR → alternativas por principio activo. Además, su evaluación es viable (acierto de mapeo y coherencia de alternativas).
- **Problema 2: Ineficiencia en la gestión de inventarios farmacéuticos.** Aunque tiene gran impacto sistémico, suele requerir datos operativos internos (inventarios, compras, distribución) y acuerdos con actores de la cadena, lo cual dificulta un prototipo realista en el tiempo del curso.
- **Problema 3: Asimetría de información entre pacientes y el sistema de salud.** Es rele-

vante, pero su alcance es amplio (precios, disponibilidad, regulación, comparativos). Parte de esta brecha informativa se reduce abordando el Problema 1, ya que MediFinder entrega información y alternativas de manera directa al usuario.

Con base en esta comparación, se seleccionó el **Problema 1** por maximizar impacto en el paciente y ofrecer una ruta técnica clara, evaluable y escalable dentro del marco del curso.

3.2. Caracterización detallada del problema seleccionado

La Universidad Javeriana señala que el asunto no reside únicamente en la ausencia física de medicamentos, sino en fallas en el abastecimiento y la cadena asociadas a la crisis financiera del sistema Díaz, 2025.

La falta de abastecimiento y entrega de medicamentos no solo afecta a los pacientes sino también a hospitales. Durante el año pasado, por suspensión de actividades de empresas productoras a nivel nacional, el Ministerio de Salud reportó escasez de fármacos vitales como norepinefrina o vasopresina (usados principalmente en UCI). En el caso de la norepinefrina, el mercado está cubierto en un 26 % por Laboratorios Ryan con 120.000 ampollas mensuales entre septiembre y diciembre; sin embargo, dicha cantidad no ha sido suficiente para cubrir la demanda, motivo por el cual el medicamento permanece en la lista de vital no disponible desde 2018 Saavedra, 2025.

Debido a esto, se otorgaron licencias y autorizaciones de importación a empresas externas. Empresas como Holland Group, Pisa Farmacéutica, Reprefarco y Sicmafarma facilitaron la llegada de unidades importadas; por ejemplo, se reportaron aproximadamente 100.000 unidades a través de Reprefarco, además de aportes de Nextpharmasourcing, lo cual incrementa costos en un contexto de crisis Saavedra, 2025.

Asimismo, a pesar de que se incrementa el desembolso de los colombianos en compra de medicamentos, esto no garantiza acceso oportuno. Persisten demoras extensas, faltantes y alzas en precios, generando inconformidad entre población dependiente de tratamientos (enfermedades crónicas, patologías huérfanas o tratamientos de alto costo) Calero, 2025.




Imagen 1. Detalle del gasto en salud por categorías 2021-2025

GRUPO ANATÓMICO	2021-2022	2022-2023	2023-2024	2021-2024
A - Tracto alimentario y metabolismo	-12,1%	2,2%	22,9%	10,3%
B - Sangre y órganos hematopoyéticos	12,6%	-17,8%	28,1%	18,6%
C - Sistema cardiovascular	2,0%	-12,1%	-5,0%	-14,8%
D - Dermatológicos	-17,6%	1,2%	-3,8%	-19,7%
G - Sistema genitourinario y hormonas sexuales	1,8%	-14,1%	13,6%	-0,7%
H - Preparados hormonales sistémicos	-5,6%	-4,5%	-2,0%	-11,7%
J - Antiinfecciosos para uso sistémico	-0,6%	-16,2%	7,1%	-10,8%
L - Agentes antineoplásicos e inmunomoduladores	12,3%	-60,3%	3,7%	-53,8%
M - Sistema musculoesquelético	7,9%	-9,6%	8,6%	6,0%
N - Sistema nervioso	-2,0%	-6,8%	10,2%	0,7%
P - Productos antiparasitarios	-18,8%	-22,0%	-0,6%	-37,1%
R - Sistema respiratorio	17,9%	-24,7%	-5,1%	-15,7%
S - Órganos de los sentidos	18,9%	-3,0%	8,6%	25,2%
SD - Sin dato	-0,5%	-13,8%	65,4%	41,9%
V - Varios	-6,2%	23,8%	-6,2%	8,8%
TOTAL GENERAL	-1,2%	-9,5%	11,0%	-0,7%

Fuente: Cubo SISMED - Bodega SISPRO MSPS - Fecha de Corte: Años 2021- 2024. Parámetros de consulta: Transacción: Primaria, Canal: Comercial , Tipo reporte precio: Venta Nota: Categoría SD- Sin dato información de grupos anatómicos que no cruzan en el reporte agregada por el MSPS. Fecha de Consulta: 07/07/2025

Imagen 2. Evolución del gasto privado en medicamentos en Colombia 2021-2025

Como se evidencia en las gráficas anteriores, el gasto privado en salud aumentó en los últimos años, pasando de 20 billones a 29.2 billones entre 2021 y 2024, con un aumento nominal del

48.0 % y del 13.8 % después de inflación Acemi, 2025.

Igualmente, el gasto en medicamentos no incluye costos adicionales asociados a la gestión para la disposición de medicinas en gestores farmacéuticos o prestadores de servicios de salud Acemi, 2025.

En síntesis, la problemática es compleja y de alcance nacional. Sin embargo, la espera por soluciones estructurales puede dejar a los pacientes expuestos a interrupciones de tratamiento. En este contexto, una herramienta tecnológica de apoyo, basada en IA, puede ofrecer alternativas temporales e información útil al usuario mientras se estabiliza el sistema.

4. Objetivos

4.1. Objetivo general

Estudiar la situación país sobre las problemáticas de la deuda de las EPS y todos sus desenlaces; ante ello, colocar el foco sobre el tema de los medicamentos y buscar la solución adecuada de un modelo de inteligencia artificial que otorgue un apoyo a todo este conflicto crítico.

4.2. Objetivos específicos

1. Investigar alternativas ya implementadas sobre programas y/o modelos IA que ayuden al paciente a la búsqueda de alternativas para un medicamento y le informe al paciente sobre el medicamento.
2. Hacer una investigación de IA en la búsqueda de alternativas para un medicamento mediante KNN.
3. Hacer una investigación de IA en la búsqueda de alternativas para clasificación de medicamentos mediante CNN.
4. Realizar un prototipo (MVP) del modelo IA planteado.

5. Marco Teórico

5.1. EPS e IPS

Puede llegar a existir la confusión entre estos dos términos los cuales provienen de la Ley 100 la cual reglamenta el sistema de salud colombiano y provee las herramientas para la financiación y sostenibilidad de su estructura procurando garantizar una atención igualitaria para todas las personas.

En primer lugar, las EPS, Entidades Promotoras de Salud, son las responsables de la afiliación y el registro de los afiliados y del recaudo de sus cotizaciones. Como dice artículo publicado por la Alcaldía de Bogotá:

Su función básica es organizar y garantizar la prestación del Plan Obligatorio de Salud (POS) y hacer los giros respectivos al Fondo de Solidaridad y Garantía que es donde se administran los recursos del Sistema de Seguridad Social en Salud. Así, todas las personas se afilian a estas y quedan amparados en su intermediación para acceder a los servicios médicos. Arias, 2021

Por otro lado, las IPS, Instituciones Prestadoras de Servicios de Salud, corresponden a todas las entidades, asociaciones y/o personas bien sean públicas, privadas o con economía mixta, que están autorizadas para prestar de forma parcial y/o total los procedimientos que se demanden para cumplir el Plan Obligatorio de Salud (POS). Dentro de este grupo es que entran los hospitales, clínicas y distintos centros de salud.

5.2. Deuda de las EPS

El año pasado, mediante un boletín de prensa, el número 093-2025, del día 15 de Julio, emitió el último informe (hasta ese momento) por parte de la Contraloría General de la República sobre la situación financiera del sistema de salud que revela 29 Entidades Promotoras de Salud (EPS) acumulan una deuda que asciende a los \$32,9 billones de pesos por servicios prestados por clínicas, hospitales, laboratorios, operadores farmacéuticos y otros actores del sistema.

Esta cifra, como bien se da en el informe dado por la Contraloría, representó un aumento de \$7.9 billones comparado al monto reportado en 2023, lo cual claramente refleja un desorden a nivel económico desde la parte administrativa en el que se encuentra todo el sistema de salud, que como expresan en el reporte, es “debido al actual modelo de aseguramiento basado en la intermediación.” Ministerio de Salud y Protección Social de Colombia, 2025

Como consecuencia a ello, la deuda en primera instancia afecta gravemente la estabilidad de los prestadores y proveedores de servicios, pero se genera una cadena llegando a afectar también de sobremanera a los usuarios, en donde se llega a violar el derecho fundamental a la salud en escenarios como barrera en el acceso con los largos retrasos para citas y cirugías, el desabastecimiento de insumos médicos y tecnologías necesarias y llegando a declararlo ya como emergencia humanitaria (por parte de AFIDRO - Asociación de Laboratorios Farmacéuticos de Investigación).

Es válido mencionar que, dentro de este boletín, lo dicho es que la culpa no recae en el gobierno, sino que va directamente a las EPS, de sus decisiones, omisiones y su mala organización administrativa.

5.3. Reconocimiento Óptico de Caracteres (OCR)

El Reconocimiento Óptico de Caracteres (*Optical Character Recognition*, OCR) es un conjunto de técnicas que permite **extraer texto desde imágenes**. En el contexto de *MediFinder*, el OCR es especialmente relevante porque tanto las **cajas de medicamentos** como la **parte trasera del blíster** suelen incluir texto con información crítica (nombre, concentración, forma farmacéutica, laboratorio y en algunos casos registro).

En términos generales, un sistema de OCR aplicado a fotografías tomadas por usuarios suele incluir:

- **Preprocesamiento:** corrección de inclinación/rotación, aumento de contraste, reducción de ruido y recorte de regiones con texto.
- **Detección de texto:** localizar regiones donde probablemente hay texto (por ejemplo, líneas o bloques).
- **Reconocimiento:** convertir píxeles a caracteres para obtener una cadena de texto.
- **Postprocesamiento:** limpieza y normalización del texto (tildes, mayúsculas, unidades como mg/mL, abreviaturas) y corrección de errores típicos (por ejemplo, confusiones entre “O” y “0”).

En un MVP orientado al usuario, es una buena práctica incorporar una etapa de **verificación humana** (el usuario corrige el texto detectado) para disminuir los efectos de errores de OCR causados por baja iluminación, reflejos (comunes en blíster) o desenfoque.

5.4. Redes Neuronales Convolucionales (CNN)

Para poder definir las redes neuronales convolucionales, en primer lugar, toca dar paso a la definición y el funcionamiento de las redes neuronales en sí.

IBM, dentro de su página web, brinda la definición al respecto de este tema:

Las redes neuronales son un subconjunto del machine learning y están en el corazón de los algoritmos de deep learning. Están compuestas por capas de nodos, que incluyen una capa de entrada, una o más capas ocultas y una capa de output. Cada nodo está conectado a otro y tiene un peso y un umbral asociados. IBM, 2025

Es válido hacer la mención de la definición general de las redes neuronales debido a que existen varios tipos usados para distintos casos y para distintos tipos de datos. Por ejemplo, las redes neuronales recurrentes se suelen usar para el procesamiento del lenguaje natural y el reconocimiento de voz. Y están las redes neuronales convolucionales, que son utilizadas principalmente para tareas de clasificación y computer vision.

El funcionamiento de este tipo de redes neuronales es destacable en el área de imágenes, voz o audio, y se componen de tres tipos de capas (principalmente): capa convolucional, capa de agrupación y la capa totalmente conectada.

En *MediFinder*, la CNN se contempla principalmente como un **mecanismo de respaldo** (fall-back) en los casos donde el OCR falle (por ejemplo, texto ilegible por reflejos en el blíster). En ese escenario, la CNN puede extraer un **embedding visual** del empaque para recuperar candidatos cercanos por similitud y luego cruzarlos con metadata del catálogo.

5.5. K-Nearest Neighbors (KNN)

Por otro lado, el enfoque del proyecto no se basa únicamente en extraer texto (OCR), sino también en recomendar alternativas. Para esto, se usa el algoritmo *k-nearest neighbors* (KNN) como método de **búsqueda por similitud** dentro de un catálogo de medicamentos, aprovechando atributos como principio activo principal, concentración, forma farmacéutica o representaciones vectoriales (embeddings).

En su definición, el algoritmo de k-nearest neighbors (KNN) es un clasificador de aprendizaje supervisado no paramétrico, que emplea la proximidad para realizar clasificaciones o predicciones sobre la agrupación de un punto de datos individual. Hoy en día, es uno de los clasificadores de clasificación y regresión más sonados además de sencillos de implementar.

Ante la explicación precisa del funcionamiento del supuesto de que hay puntos similares cercanos, dentro de la página de IBM:

En los problemas de clasificación, la etiqueta de clase se asigna por mayoría de votos, es decir, se emplea la etiqueta que se representa con más frecuencia en torno a un punto de datos determinado. Aunque técnicamente se considera “votación por pluralidad”, el término “votación por mayoría” se emplea más comúnmente en las publicaciones al respecto. La distinción entre estas terminologías es que la “votación por mayoría” requiere técnicamente una mayoría superior al 50 %, lo que funciona sobre todo cuando sólo hay dos categorías. Cuando hay varias clases, por ejemplo, cuatro categorías, usted no requiere necesariamente el 50 % de los votos para llegar a una conclusión sobre una clase, ya que podría asignar una etiqueta de clase con un voto superior al 25 %. Kavlakoglu, 2025

En *MediFinder*, KNN se utiliza para **rankear alternativas** y proponer medicamentos similares, priorizando aquellos que comparten el **principio activo principal** (misma molécula). Como segundo nivel informativo (cuando el catálogo no ofrece suficientes equivalentes), se pueden mostrar alternativas de la misma **clase terapéutica** con advertencias, ya que no necesariamente son intercambiables.

6. Propuesta de solución

Reuniendo todo lo mencionado ante la problemática presente en la sociedad colombiana, que no se solucionará en el corto plazo, se propone una solución tecnológica *temporal* que ayude a los pacientes a identificar un medicamento y encontrar alternativas cuando el fármaco original no esté disponible.

La solución planteada es implementar un sistema de IA que, a partir de una fotografía del medicamento (idealmente la **caja** o la **parte trasera del blíster**), permita: (i) reconocer el medicamento mediante extracción y verificación de texto (OCR) y (ii) recomendar alternativas farmacéuticas con base en el **principio activo principal**. El MVP se apoya en fuentes colombianas (INVIMA y *Medicamentos a un Clic*) y en un motor de similitud basado en KNN.

6.1. Prototipo de papel

La Figura 3 ilustra el prototipo conceptual del sistema, que define el flujo mínimo de interacción: captura/subida de imagen, verificación de texto detectado (OCR) y presentación de información y alternativas.




Imagen 3. Prototipo de papel (wireframe) del MVP de MediFinder: captura/subida, extracción y verificación (OCR) y resultados con función del medicamento y alternativas (KNN por principio activo).

6.2. Prototipo de interfaz

Además del wireframe en papel, se desarrolló un prototipo de interfaz digital para validar la experiencia de usuario y la navegación del MVP.

- **Link de figma:** <https://city-wasp-51690509.figma.site/>
- **Link Video demo:** <https://youtu.be/q5UDXb44g08>




Imagen 4. Pantalla 1 del prototipo de interfaz de MediFinder.

← 

Verifica el medicamento

Revisa que la información extraída sea correcta




Imagen capturada

Nombre comercial	
Paracetamol MK	
Principio activo	
Paracetamol	
Concentración	
500 mg	
Forma farmacéutica	
Cápsula	
Registro INVIMA (si aparece)	
2019M-0009876-R2	

 Confirmar datos

Asegúrate de que la información sea correcta antes de continuar

Imagen 5. Pantalla 2 del prototipo de interfaz de MediFinder.




Imagen 6. Pantalla 3 del prototipo de interfaz de MediFinder.

6.3. Arquitectura del sistema (MVP)

El MVP se organiza como un pipeline en tres pasos, alineado con el flujo del prototipo:

6.3.1. Paso 1: Captura de imagen y preprocesamiento

- El usuario toma o sube una imagen de la **caja del medicamento** o la **parte trasera del blíster**.
- Se aplica preprocesamiento para mejorar la legibilidad: corrección de rotación, ajuste de contraste y normalización del tamaño.
- Se muestran recomendaciones de captura (buena luz, enfoque y sin reflejos) para reducir errores.

6.3.2. Paso 2: Extracción y verificación de texto (OCR + normalización)

- Se aplica OCR para extraer texto relevante del empaque/blíster (principalmente el **nombre del medicamento** y, cuando sea posible, concentración y forma farmacéutica).
- El sistema presenta los campos detectados de forma **editable** para que el usuario corrija errores frecuentes del OCR.
- Se normaliza el texto (tildes, mayúsculas/minúsculas, abreviaturas, unidades) y se realiza un proceso de *matching* para mapear el texto a un registro del catálogo.

6.3.3. Paso 3: Consulta de información y recomendación de alternativas (KNN)

Una vez identificado el medicamento, el sistema:

- consulta la información disponible en fuentes colombianas y el catálogo consolidado del proyecto;
- muestra la **función del medicamento** (tipo terapéutico y usos/indicaciones generales);
- calcula **alternativas similares por principio activo principal** usando KNN:
 - **Prioridad 1 (equivalentes):** misma molécula (mismo principio activo principal) y, de ser posible, misma concentración y forma farmacéutica.
 - **Prioridad 2 (similares por clase):** misma clase terapéutica cuando no existan suficientes equivalentes por molécula (se presenta como sugerencia informativa).

6.4. Fuentes de datos (Colombia) e integración

El MVP se apoya en fuentes y plataformas con información relevante para Colombia:

- **INVIMA** (listado de registros sanitarios de medicamentos) Instituto Nacional de Vigilancia de Medicamentos y Alimentos (INVIMA), 2026.
- **Medicamentos a un Clic** (consulta de información de medicamentos autorizados y regulados) Ministerio de Salud y Protección Social de Colombia, 2026.

En el prototipo, la información se consolida en un catálogo mínimo (por ejemplo CSV/JSON) para: (i) mapear el medicamento detectado a su principio activo principal y (ii) habilitar el ranking de alternativas por similitud.

7. Enfoque metodológico y técnico

El proyecto adopta un enfoque de prototipado incremental orientado a un **MVP funcional** con alcance en Colombia. La meta es entregar un flujo completo y evaluable: desde una fotografía del empaque hasta una lista de alternativas por principio activo, con información básica del medicamento.

7.1. Decisiones metodológicas (por qué este enfoque)

- **OCR como núcleo de identificación:** para cajas y blísteres, el texto (nombre, concentración, forma) es la señal más informativa y estable. Por ello, el MVP prioriza OCR y verificación manual.
- **KNN como motor de recomendación:** dado un medicamento identificado y su principio activo, se utiliza KNN (sobre atributos/representaciones del catálogo) para ordenar alternativas y recuperar equivalentes.
- **Fuentes oficiales en Colombia:** el sistema se apoya en INVIMA y *Medicamentos a un Clic* como fuentes principales de consulta y validación de información Instituto Nacional de Vigilancia de Medicamentos y Alimentos (INVIMA), 2026; Ministerio de Salud y Protección Social de Colombia, 2026.

7.2. Pipeline técnico del MVP

El MVP se compone de los siguientes módulos:

7.2.1. Módulo 1: Ingesta de imagen

- Entrada: foto de caja o parte trasera del blíster.
- Preprocesamiento: rotación, contraste, reducción de ruido, y recorte cuando aplique.

7.2.2. Módulo 2: OCR + normalización + mapeo a medicamento

- OCR extrae texto del empaque/blíster.
- El usuario confirma/corriga campos críticos (minimiza fallos por OCR).

- Normalización: limpieza de texto, unidades, tildes, variantes.
- Mapeo: vincular el texto a un registro del catálogo (por ejemplo mediante similitud de strings y claves).

7.2.3. Módulo 3: Enriquecimiento + recomendaciones por principio activo (KNN)

- Se consulta la metadata del medicamento: principio activo principal, concentración, forma y función (tipo y usos).
- Se generan alternativas:
 - **Equivalentes por molécula:** misma molécula (principio activo principal), idealmente misma concentración/forma.
 - **Similares por clase:** alternativa secundaria informativa cuando no existan equivalentes suficientes.
- El ranking final se obtiene con KNN y reglas de filtro por principio activo y forma farmacéutica.

7.3. Evaluación (qué se medirá)

Para evaluar el prototipo, se medirán:

- **Calidad de OCR/mapeo:** tasa de acierto del nombre detectado (antes y después de corrección del usuario) y porcentaje de casos que se mapean correctamente a un registro del catálogo.
- **Calidad de recomendación:** proporción de alternativas que coinciden en principio activo (Nivel 1) y coherencia en forma/concentración cuando exista esa información.
- **Tiempo de respuesta:** tiempo total desde captura hasta resultados (OCR + consulta + KNN).

7.4. Extensión prevista (CNN como respaldo)

Como línea de mejora, se considera integrar una CNN como respaldo cuando el texto sea ilegible (borroso, reflejos, baja luz), permitiendo extraer un embedding visual del empaque

para recuperar candidatos probables y luego aplicar las mismas reglas de enriquecimiento y recomendación. Esta extensión no es requerida para el MVP, pero se deja documentada como escalabilidad técnica.

8. Evaluación

Esta sección documenta los resultados obtenidos al ejecutar el MVP de MediFinder sobre casos de prueba reales, evaluando el pipeline completo: captura de imagen, OCR, mapeo al catálogo INVIMA, recomendación KNN y explicación por LLM.

8.1. Casos de falla

Caso de falla 1: Naproxeno Sódico 275 mg — imagen tomada en ángulo con mano visible en el encuadre

Descripción del escenario. El usuario fotografía la caja de NAPROXENO SÓDICO 275 MG (MK) sosteniéndola con la mano, con el encuadre inclinado y parte del fondo (ropa de color rojo) visible. La imagen no presenta condiciones de captura controladas: el ángulo de la caja respecto al plano de la cámara es aproximadamente 30°.

Secuencia de entradas y salidas obtenidas.

1. **Entrada:** imagen JPEG con encuadre oblicuo, mano sosteniendo el medicamento y fondo de color visible.
2. **OCR:** Tesseract logra extraer texto con una confianza reportada del 95 %; sin embargo, el texto extraído no produce una coincidencia válida en el catálogo INVIMA — la perspectiva oblicua genera distorsión geométrica que afecta la legibilidad de las líneas de texto. El sistema evalúa la extracción como no aprovechable para el mapeo y activa el *fallback* CNN. Badge reportado en interfaz: “*Confianza OCR: 95 %*” con indicador de advertencia.
3. **Fallback CNN:** EfficientNet-B0 genera el embedding de la imagen y consulta la base de embeddings visuales en ChromaDB. La imagen en perspectiva oblicua produce un vector de características que no supera el umbral de similitud mínimo (0,45) respecto a ninguna imagen de referencia del catálogo visual, que fue construido con imágenes frontales en condiciones controladas. Badge reportado: “*Identificado por visión (CNN)*”.
4. **Resultado:** todos los campos de la pantalla de verificación permanecen vacíos (placeholders), como se muestra en la Imagen 7. El sistema muestra el banner de advertencia: “*No se pudo leer el texto de la imagen*”, con las recomendaciones: asegurarse de que el nombre sea visible y esté enfocado, usar buena iluminación, fotografiar la caja (no el blíster), o bien ingresar directamente el principio activo de forma manual.

Verifica el medicamento

Revisa que la información extraída sea correcta

Identificado por visión (CNN) Confianza OCR: 95%



Nombre comercial	Ej: Ibuprofeno Genfar
Principio activo *	Ej: Ibuprofeno
Concentración	Ej: 400 mg
Forma farmacéutica	Ej: Tableta
Registro INVIMA	Ej: 2020M-0012345-R1

No se pudo leer el texto de la imagen.

- Asegúrate de que el **nombre del medicamento sea visible** y esté enfocado
- Usa **buena iluminación** y evita reflejos en el empaque
- Fotografía la **caja** (no el blíster) para obtener mejor texto

O bien, escribe directamente el **principio activo** (ej: ibuprofeno, paracetamol) y presiona **Confirmar datos** para buscar alternativas.

Imagen 7. *Falla de identificación para Naproxeno Sódico 275 mg. El ángulo oblicuo de captura y la presencia de la mano en el encuadre impiden tanto el OCR como la búsqueda visual CNN. El sistema presenta campos vacíos y guía al usuario hacia la entrada manual.*

Análisis del resultado. La falla en este caso es atribuible exclusivamente a las condiciones de captura: el ángulo de la imagen introduce distorsión de perspectiva que afecta la geometría del texto, reduciendo la eficacia de Tesseract incluso cuando la confianza por caracteres individuales es alta (95 %). La coexistencia de una confianza OCR elevada con una falla en el mapeo al catálogo evidencia que la métrica de confianza de Tesseract no captura la corrección semántica del texto extraído, sino únicamente la certeza del reconocimiento de cada carácter individualmente. El sistema responde de forma segura: no produce una identificación incorrecta, sino que presenta campos vacíos y proporciona instrucciones concretas para que el usuario mejore la captura o ingrese el principio activo manualmente.

Caso de falla 2: Omeprazol — imagen con caja sostenida verticalmente en ángulo lateral

Descripción del escenario. El usuario fotografía una caja de OMEPRAZOL (La Santé) sosteniéndola verticalmente con la mano. La imagen presenta la caja en posición lateral, de forma que la cara frontal no queda perpendicular al plano de la cámara. La cara lateral angosta del empaque (que muestra el nombre en sentido vertical) es la que queda parcialmente visible.

Secuencia de entradas y salidas obtenidas.

1. **Entrada:** imagen JPEG con la caja orientada lateralmente, texto principal en disposición vertical respecto al sensor.
2. **OCR:** la corrección de rotación por evaluación de las cuatro orientaciones cardinales (0° , 90° , 180° , 270°) selecciona la orientación de mayor confianza; sin embargo, dado que la cara visible del empaque es la lateral (con texto en sentido perpendicular a la cara principal), el texto farmacéuticamente relevante (nombre comercial, concentración) no está completamente expuesto. Confianza reportada: 95 % sobre los caracteres detectados, con falla en el mapeo al catálogo. Se activa el *fallback* CNN.
3. **Fallback CNN:** la búsqueda visual en ChromaDB no supera el umbral de similitud mínimo. La vista lateral del empaque produce un embedding que no tiene correspondencia en la base de imágenes de referencia, construida con fotografías frontales. Badge reportado: “Identificado por visión (CNN)”.
4. **Resultado:** todos los campos de la pantalla de verificación permanecen vacíos, como se muestra en la Imagen 8. Se despliega el banner de advertencia con las mismas recomendaciones del caso anterior.




Imagen 8. *Falla de identificación para Omeprazol con caja sostenida lateralmente. La orientación de la imagen expone la cara lateral del empaque en lugar de la frontal, impidiendo tanto el OCR como la búsqueda visual CNN.*

Análisis del resultado. Este caso y el anterior comparten la causa raíz: condiciones de captura que exponen al sistema a una vista del empaque para la cual ni el OCR ni el CNN tienen representación adecuada. La diferencia respecto al Caso de falla 1 (blíster metálico) es que aquí la información sí existe en la imagen — el nombre del medicamento es legible a simple vista —, pero la geometría de la captura la hace inaccesible para el pipeline actual.


Ambos casos de falla por ángulo oblicuo sugieren una mejora de alto impacto: incorporar una etapa de **detección de calidad de imagen** previa al OCR que evalúe métricas como el ángulo de inclinación estimado del empaque (mediante detección de bordes o homografía), la presencia de objetos en el encuadre (manos, fondos de color) y el porcentaje del área útil ocupado por el empaque. Si estas métricas no superan umbrales mínimos, el sistema podría solicitar una nueva captura antes de ejecutar el pipeline, evitando procesamiento innecesario y mejorando la experiencia del usuario.

Caso 1: Acetaminofén 500 mg — fotografía de caja con luz natural, identificación por OCR

Descripción del escenario. El usuario fotografía la cara frontal de una caja de ACETAMINOFÉN 500 MG TABLETA (Bayer S.A.) bajo luz natural. La imagen presenta fondo azul con texto blanco y amarillo, condición que históricamente representa un reto para el preprocesamiento monocromático estándar.

Secuencia de entradas y salidas obtenidas.

1. **Entrada:** imagen JPEG de la caja del medicamento cargada desde la interfaz web.
2. **Preprocesamiento OCR:** el pipeline evalúa múltiples estrategias de preprocesamiento (umbral suave Otsu, umbral agresivo CLAHE, canales de color R y diferencia R-B) con cuatro modos PSM de Tesseract (3, 4, 6, 11), aplicadas sobre la imagen escalada $2\times$. La variante con mayor confianza es seleccionada automáticamente. Adicionalmente, la corrección de rotación prueba las cuatro orientaciones cardinales (0° , 90° , 180° , 270°) y retiene la de mayor confianza, previniendo lecturas invertidas como las observadas en pruebas previas con empaques de fondo multicolor.
3. **Salida OCR:** texto extraído ".^aCETAMINOFEN 500 MG TABLETA", confianza Tesseract **99 %**. `ocr_exitoso = True`. Badge en pantalla: "*Identificado por OCR*".
4. **Mapeo al catálogo INVIMA:** la función `buscar_pa_por_nombre` aplica una cascada de búsqueda: (0) cada palabra significativa del texto OCR se intenta como principio activo directo — la palabra ".^acetaminofen" produce coincidencia exacta en la columna `principio_activo` del catálogo; (1) coincidencia exacta de nombre comercial; (2) contención por palabra más larga; (3) *fuzzy matching* con *rapidfuzz*. En este caso el nivel 0 resuelve la búsqueda. Score de *match* catálogo reportado en interfaz: **99 %**. Registro encontrado: "ACETAMINOFÉN 500 MG TABLETA", titular BAYER S.A., registro INVIMA 2014M-0014587-R1, clase terapéutica: *analgésicos y antipiréticos*, vía: oral.
5. **Pantalla de verificación:** el sistema presenta los campos prepopulados como se muestra en la Imagen 9: nombre comercial, principio activo (*paracetamol*), concentración (500 mg), forma farmacéutica (tableta) y registro INVIMA. El usuario confirma los datos sin necesidad de corrección manual.



Verifica el medicamento
Revisa que la información extraída sea correcta

Identificado por OCR ✓ Confianza OCR: 99% Match catálogo: 99%



Nombre comercial
ACETAMINOFEN 500 MG TABLETA

Principio activo *
paracetamol

Concentración
500 mg

Forma farmacéutica
tableta

Registro INVIMA
INVIMA 2014M-0014587-R1

Titular: BAYER S.A.
Clase: analgésicos y antipiréticos
Vía: oral

✓ Se encontraron 1 alternativas. Explicación del principio activo lista. Confirma los datos para ver los resultados.

✓ Confirmar datos

Asegúrate de que la información sea correcta antes de continuar

Imagen 9. Pantalla de verificación para Acetaminofén 500 mg. OCR con 99 % de confianza y match de catálogo al 99 %.

- KNN — búsqueda de alternativas:** con el principio activo "paracetamol" identificado, el modelo *NearestNeighbors* busca los $k = 5$ medicamentos más similares en el espacio de características farmacológicas (principio activo codificado, concentración, forma farmacéutica, clase terapéutica, vía de administración). La deduplicación por nombre normalizado elimina entradas redundantes del catálogo INVIMA. Se retorna **1 alternativa de nivel 1** (mismo principio activo): **ROBAXIFEN 400 TABLETAS** (paracetamol, tableta, Wyeth Consumer Healthcare Ltd.), similitud 100 %.
- LLM (Claude Haiku + RAG):** el módulo recupera contexto desde la *knowledge base* en ChromaDB (11.217 documentos de principios activos). La explicación generada para *paracetamol* (*acetaminofén*) cubre seis secciones estructuradas presentadas de forma compacta: **Qué es** (analgésico y antipirético, conocido también como Tylenol o Panadol), **Cómo actúa** (bloqueo de la producción de sustancias que generan dolor e inflamación), **Efectos secundarios** (bien tolerado en dosis normales; uso excesivo puede afectar el hígado), **Contraindicaciones** (alergia conocida al paracetamol, enfermedad hepática severa, consumo crónico de alcohol), **Interacciones** (potencia efecto analgésico con ibuprofeno).

bajo supervisión; riesgo de daño hepático con otros medicamentos) y **Recomendaciones** (seguro en embarazo y lactancia; disponible en múltiples formas farmacéuticas en Colombia), como se observa en la Imagen 11.




Imagen 10. Pantalla de resultados: medicamento identificado, 1 alternativa encontrada con similitud 100 % y sección expandible de información del principio activo.




Imagen 11. Explicación del principio activo paracetamol (acetaminofén) generada por Claude Haiku con RAG, presentada en seis secciones clínicas estructuradas y contextualizadas para el paciente colombiano.

8. **Salida final:** pantalla de resultados con el medicamento identificado, 1 alternativa única con badge “Mismo principio activo” y “Similitud 100 %”, información del titular INVIMA, y explicación completa del principio activo expandible en pantalla (Imágenes 9, 10 y 11).

Resultado logrado. El sistema identificó el medicamento con la mayor confianza registrada en las pruebas (99 % OCR, 99 % catálogo), sin intervención del usuario. El paso 0 de la cascada de búsqueda — verificación directa de cada palabra OCR como principio activo en el catálogo — resultó determinante: la palabra “acetaminofen” presente en el empaque es simultáneamente el nombre comercial y el principio activo, lo que eliminó la necesidad de búsqueda por nombre comercial o *fuzzy matching*. La corrección automática de rotación por evaluación de las cuatro orientaciones cardinales garantizó que el texto del empaque de fondo azul multicolor fuera leído en la orientación correcta, a diferencia de pruebas anteriores donde la heurística OSD producía lecturas invertidas. La explicación LLM, respaldada por RAG sobre la base de conocimiento, entregó información clínicamente estructurada y contextualizada para el mercado colombiano.

Caso 2: Doxyciclina 100 mg — fotografía de caja, fallo parcial del módulo LLM por confusión semántica en RAG

Descripción del escenario. El usuario fotografía la cara frontal de una caja de DOXICICLINA 100 MG CÁPSULAS (Laboratorios Legrand S.A., Genfarma) bajo condiciones normales de iluminación. La caja presenta fondo rojo y blanco con texto negro, combinación favorable para el procesamiento OCR estándar.

Secuencia de entradas y salidas obtenidas.

1. **Entrada:** imagen JPEG de la caja del medicamento cargada desde la interfaz web.
2. **Preprocesamiento OCR:** el pipeline evalúa las variantes de preprocesamiento y modos PSM disponibles sobre la imagen escalada $2\times$. La corrección de rotación por evaluación de las cuatro orientaciones cardinales confirma que la imagen ya se encuentra en la orientación correcta (0°). El alto contraste texto negro sobre fondo blanco favorece la variante de umbral Otsu con PSM 6.
3. **Salida OCR:** texto extraído "DOXICICLINA 100 MG CAPSULAS", confianza Tesseract **99 %**. `ocr_exitoso = True`. Badge en pantalla: *"Identificado por OCR"*.
4. **Mapeo al catálogo INVIMA:** la cascada de búsqueda en `buscar_pa_por_nombre` resuelve en el nivel 0: la palabra "doxyciclina" presente en el texto OCR produce coincidencia exacta en la columna `principio_activo` del catálogo. Score de *match* reportado en interfaz: **99 %**. Registro encontrado: "DOXICICLINA 100 MG CÁPSULAS", titular Laboratorios Legrand S.A., registro INVIMA 2009M-0009264, clase terapéutica: *antibióticos tetraciclinas*, vía: oral.
5. **Pantalla de verificación:** el sistema presenta los campos prepopulados correctamente — nombre comercial, principio activo (*doxyciclina*), concentración (100 mg), forma farmacéutica (*cápsula dura*) y registro INVIMA — como se observa en la Imagen 12. El usuario confirma sin corrección manual.




Imagen 12. Pantalla de verificación para Doxiciclina 100 mg. OCR y match de catálogo al 99 %, campos prepopulados correctamente sin intervención del usuario.

6. **KNN — búsqueda de alternativas:** con el principio activo "doxiciclina" confirmado, el modelo *NearestNeighbors* retorna **1 alternativa de nivel 1** tras deduplicación: **DOXICICLINA 100 MG. CÁPSULAS** (principio activo: *doxiciclina clorhidrato equivalente a doxiciclina*, forma: cápsula dura, titular: Laboratorios Farmacéuticos Ophalacs S.A.), similitud 100 %. El número reducido de alternativas refleja la baja diversidad de presentaciones de doxiciclina registradas actualmente en el catálogo INVIMA disponible.
7. **LLM (Claude Haiku + RAG) — fallo parcial por confusión semántica:** el módulo de recuperación de contexto realiza una búsqueda semántica sobre la *knowledge base* en ChromaDB usando el vector del principio activo "doxiciclina". El documento más cercano recuperado corresponde a **doxazosina**, un alfabloqueante para hipertensión y próstata, semánticamente próximo a "doxiciclina" por similitud léxica superficial (prefijo "doxa-"/"doxi-") en el espacio de embeddings. En consecuencia, la explicación generada describe incorrectamente a la doxazosina en lugar de la doxiciclina, como se observa en la Imagen 13.




Imagen 13. Pantalla de resultados para Doxyciclina 100 mg. El KNN identifica correctamente 1 alternativa con similitud 100 %; sin embargo, la sección de información del principio activo muestra una explicación sobre doxazosina en lugar de doxiciclina, evidenciando una falla en la recuperación RAG por similitud léxica espuria.

8. **Salida final:** el medicamento y la alternativa KNN se identifican correctamente. El módulo LLM produce una explicación incorrecta del principio activo por confusión semántica en la etapa de recuperación RAG.

Análisis del resultado. Este caso ilustra una falla parcial del sistema: los módulos OCR, mapeo al catálogo y KNN operan correctamente con confianza máxima, mientras que el módulo LLM produce una respuesta clínicamente incorrecta. La causa raíz es una limitación del modelo de embeddings de texto utilizado (*paraphrase-multilingual-MiniLM-L12-v2*): los vectores de "doxiciclina" y "doxazosina" son suficientemente similares en el espacio latente como para que la búsqueda por similitud coseno recupere el documento equivocado, especialmente cuando la *knowledge base* no contiene un documento específico para doxiciclina y el vecino más cercano disponible es doxazosina.

El sistema **no detecta ni advierte** esta confusión al usuario, lo que representa un riesgo en


un contexto clínico real. Las mejoras propuestas incluyen: (1) incorporar un umbral mínimo de similitud coseno en la recuperación RAG y mostrar un aviso cuando no se supere, en lugar de presentar el documento más cercano sin validación; (2) ampliar la *knowledge base* con principios activos antibióticos cuya cobertura actual es insuficiente; y (3) verificar que el principio activo recuperado en el contexto RAG coincida textualmente con el solicitado antes de invocar al LLM.

Caso 3: Cefalexina 500 mg — validación del flujo completo con cinco alternativas farmacéuticas diferenciadas

Descripción del escenario. El usuario fotografía la cara frontal de una caja de CEFALEXINA 500 MG CÁPSULAS (Laboratorios La Santé S.A.S.) bajo condiciones normales de iluminación. La caja presenta fondo amarillo y azul con texto negro, lo que representa un caso de contraste mixto para el preprocesamiento OCR.

Secuencia de entradas y salidas obtenidas.

1. **Entrada:** imagen JPEG de la caja del medicamento cargada desde la interfaz web.
2. **Salida OCR:** texto extraído "CEFALEXINA 500 MG CAPSULAS", confianza Tesseract **99 %**.
`ocr_exitoso = True`.
3. **Mapeo al catálogo INVIMA:** la cascada de búsqueda resuelve en el nivel 0 por coincidencia directa de "cefalexina" como principio activo. Score de *match*: **99 %**. Registro: "CEFALEXINA 500 MG CÁPSULAS", titular Laboratorios La Santé S.A.S., registro INVIMA M-006738-R1, clase terapéutica: *cefalosporinas de primera generación*, vía: oral.
4. **Pantalla de verificación:** campos prepopulados correctamente — principio activo (*cefalexina*), concentración (500 mg), forma (*cápsula*) — como se muestra en la Imagen 14. El usuario confirma sin corrección.



Verifica el medicamento
Revisa que la información extraída sea correcta

Identificado por OCR ✓ Confianza OCR: 99% Match catálogo: 99%

 Titular: LABORATORIOS LA SANTÉ S.A.S. Clase: cefalosporinas de primera generación Via: oral	Nombre comercial CEFALEXINA 500 MG CAPSULAS	
	Principio activo * cefalexina	
	Concentración 500 mg	
	Forma farmacéutica capsula	
	Registro INVIMA INVIMA M-006738-R1	

✓ Se encontraron 5 alternativas. Explicación del principio activo lista. Confirma los datos para ver los resultados.

✓ Confirmar datos

Asegúrate de que la información sea correcta antes de continuar

Imagen 14. Pantalla de verificación para Cefalexina 500 mg. OCR y match de catálogo al 99 %, con registro INVIMA M-006738-R1.

5. **KNN — cinco alternativas únicas con deduplicación efectiva:** con principio activo "cefalexina", el modelo retorna **5 alternativas de nivel 1** tras deduplicación por nombre normalizado y perfil clínico, como se observa en la Imagen 15:

- OSPEXINA 1000 MG TABLETAS** — cefalexina, tableta, Sandoz GmbH
- CEFALEXINA 500 MG CÁPSULAS** — cefalexina base (equivalente a 551,82 mg cefalexina monohidrato), cápsula dura, Genven Genéricos Venezolanos S.A.
- CEFALEXINA 250 MG/5 ML POLVO PARA RECONSTITUIR A SUSPENSIÓN ORAL** — cefalexina, polvo para reconstituir, Memphis Products S.A.
- OSPEXINA 250 MG/5 ML GRÁNULOS PARA SUSPENSIÓN ORAL** — cefalexina monohidrato, gránulos, Sandoz GmbH
- CEFALON ER** — cefalexina monohidrato, tableta de liberación prolongada, Laboratorios Legrand S.A.

Las cinco alternativas corresponden a presentaciones farmacéuticas genuinamente distintas (tableta, cápsula, polvo, gránulos, liberación prolongada), evidenciando que la dedupli-

cación por perfil clínico opera correctamente al eliminar las múltiples variantes de nombre con las que el INVIMA registra el mismo producto.




Imagen 15. Pantalla de resultados para Cefalexina 500 mg. Cinco alternativas únicas de nivel 1 con similitud 100 %, diferenciadas por forma farmacéutica y titular.

- LLM (Claude Haiku + RAG):** la recuperación RAG obtiene correctamente el documento de *cefalexina* de la *knowledge base*. La explicación generada describe adecuadamente el mecanismo como antibiótico betalactámico de primera generación activo frente a bacterias Gram-positivas.

Resultado logrado. Este caso valida el funcionamiento completo del pipeline sin ninguna falla en ninguno de sus módulos. El aspecto más destacable es el comportamiento del KNN con deduplicación: el catálogo INVIMA contiene decenas de registros para cefalexina, pero el

sistema devuelve únicamente las cinco presentaciones farmacéuticas clínicamente distintas, todas con similitud 100 % por compartir el mismo principio activo. Esto demuestra que la estrategia de deduplicación en dos capas (nombre normalizado y perfil clínico) cumple su objetivo de presentar alternativas realmente útiles para el usuario, sin ruido por duplicados administrativos del registro.

Caso 4: Aspirina 500 mg — fallo parcial del LLM con auto-detección de confusión semántica

Descripción del escenario. El usuario fotografía la cara frontal de una caja de ASPIRINA 500 MG TABLETA (Bayerpharma AG) bajo condiciones normales de iluminación. La caja presenta fondo verde y blanco con texto en negro y verde, tipografía de tamaño variable.

Secuencia de entradas y salidas obtenidas.

1. **Entrada:** imagen JPEG de la caja del medicamento cargada desde la interfaz web.
2. **Salida OCR:** texto extraído .^aSPIRINA 500 MG TABLETA", confianza Tesseract **99 %**.
ocr_exitoso = True.
3. **Mapeo al catálogo INVIMA:** la búsqueda resuelve por coincidencia directa de .^acido acetilsalicílico" como principio activo. Score de *match*: **99 %**. Registro: "ASPIRINA 500 MG TABLETA", titular Bayerpharma AG, registro INVIMA 2001M-0000663, clase terapéutica: *ácido acetilsalicílico y derivados*, vía: oral.
4. **Pantalla de verificación:** campos prepoplados correctamente como se muestra en la Imagen 16. El usuario confirma sin corrección.




Imagen 16. Pantalla de verificación para Aspirina 500 mg. OCR y match de catálogo al 99 %, con identificación correcta del principio activo ácido acetilsalicílico.

5. **KNN — alternativa única:** con principio activo ".ácido acetilsalicílico", el modelo retorna **1 alternativa de nivel 1: CORAZPINA BIOCARDIS** (ácido acetilsalicílico, tableta, Bioquímico Pharms A.), similitud 100 %. El número reducido de alternativas refleja que las presentaciones de ácido acetilsalicílico de 500 mg en tableta disponibles actualmente en el catálogo INVIMA consultado son escasas tras la deduplicación.
6. **LLM (Claude Haiku + RAG) — fallo con auto-detección:** la búsqueda semántica en la *knowledge base* no recupera un documento suficientemente representativo del principio activo ".ácido acetilsalicílico". A diferencia del Caso 4 (doxiciclina), en el que el LLM generó la explicación incorrecta sin advertirlo, en este caso el modelo **detecta la inconsistencia** entre el principio activo solicitado y el contexto recuperado, e informa explícitamente al usuario: "*Aclaración importante: veo que ha habido una confusión en los datos que recibí. Usted preguntó por el ÁCIDO ACETILSALICÚLICO, pero los medicamentos listados corresponden a otros principios activos*". Esta respuesta se observa en la Imagen 17.




Imagen 17. Pantalla de resultados para Aspirina 500 mg. El LLM detecta y reporta activamente la confusión semántica en la recuperación RAG, a diferencia del Caso 4 donde la explicación incorrecta se presentó sin advertencia.

Análisis del resultado. Este caso expone dos hallazgos relevantes. El primero es estructural: el KNN retorna únicamente 1 alternativa para ácido acetilsalicílico 500 mg tableta, lo que sugiere que el catálogo disponible tiene cobertura insuficiente para este principio activo en esa presentación específica, o que la deduplicación eliminó registros que podrían haber sido alternativas válidas.

El segundo hallazgo es comparativo respecto al Caso 4: el comportamiento del LLM ante una falla RAG no es determinístico. En el Caso 4 (doxiciclina), el modelo generó silenciosamente una explicación sobre doxazosina sin reportar la discrepancia. En este caso, el mismo modelo detectó la inconsistencia y emitió una advertencia explícita. Esta diferencia de comportamiento revela que la capacidad de auto-corrección del LLM depende de qué tan evidente sea la distancia semántica entre el principio activo solicitado y el contexto recuperado: cuando la similitud superficial entre los términos es muy alta (“doxi-ciclina” vs. “doxa-zosina”), el

modelo no detecta el error; cuando el contexto recuperado es claramente ajeno al principio activo consultado, el modelo logra identificar la inconsistencia. Esto refuerza la necesidad de un umbral de similitud mínimo en la capa RAG antes de invocar al LLM, independientemente del comportamiento de auto-corrección del modelo.

9. Reflexiones

9.1. Lecciones aprendidas

Acierto 1: La verificación humana como mitigador estructural de errores del pipeline

Incluir una etapa de verificación manual entre el OCR y el KNN resultó ser la decisión arquitectónica más importante del proyecto. Al mostrar los campos extraídos de forma editable antes de ejecutar las recomendaciones, el sistema puede operar con un OCR de precisión moderada sin comprometer la calidad de las alternativas entregadas. Los casos de prueba documentados en la sección anterior confirman este diseño: en los casos exitosos (Acetaminofén, Cefalexina, Aspirina, Doxiciclina), el usuario simplemente confirmó los campos prepopulados sin necesidad de corrección; en los casos de falla por ángulo oblicuo (Naproxeno, Omeprazol), el sistema presentó campos vacíos y guió al usuario a ingresar el dato manualmente, permitiendo que el resto del pipeline (KNN, LLM) funcionase correctamente a partir de ese punto.

El aprendizaje es que en aplicaciones de salud donde el costo de un error es alto, diseñar *checkpoints* humanos explícitos en el pipeline es más robusto que intentar eliminar todos los errores del modelo de IA. La verificación humana no es un parche: es parte del diseño que hace al sistema confiable incluso cuando sus componentes individuales fallan.

Acierto 2: La estrategia de búsqueda en cascada como solución al problema de mapeo OCR → principio activo

Una de las correcciones más impactantes del proyecto fue la implementación de la función `buscar_pa_por_nombre` con una cascada de cuatro niveles: (0) verificación directa de cada palabra significativa del texto OCR como principio activo en el catálogo, (1) coincidencia exacta de nombre comercial, (2) contención por la palabra más larga en nombres del catálogo, y (3) *fuzzy matching* con *rapidfuzz*. El nivel 0 resolvió eficientemente los casos donde el empaque incluye el principio activo en su texto visible (Acetaminofén, Cefalexina), mientras que los niveles superiores cubrieron casos con nombres comerciales diferenciados.

Esta solución también requirió identificar y filtrar *stopwords* farmacéuticas genéricas (“medicamento”, “comprimidos”, “cápsula”, entre otras) para evitar falsos positivos: en pruebas

iniciales, el sistema mapeó la lectura “medicamento ficticio” a “cefalotina” porque la palabra “medicamento” producía coincidencia parcial con entradas del catálogo que contienen la cadena “GRUPO DE MEDICAMENTOS”. La corrección consistió en excluir estas palabras antes de cualquier búsqueda. El aprendizaje es que el vocabulario del dominio farmacéutico contiene términos de alta frecuencia que, sin filtrado previo, contaminan cualquier estrategia de búsqueda por similitud.

Acierto 3: La evaluación de múltiples estrategias OCR como respuesta a la diversidad de empaques farmacéuticos

El pipeline OCR final evalúa hasta seis variantes de preprocesamiento (umbral suave Otsu, umbral agresivo CLAHE, canal rojo, diferencia de canales R–B, entre otros) combinadas con cuatro modos PSM de Tesseract (3, 4, 6, 11), aplicadas sobre una imagen escalada al doble de su resolución original. Adicionalmente, la corrección de orientación evalúa las cuatro rotaciones cardinales (0° , 90° , 180° , 270°) en lugar de depender del detector OSD de Tesseract, que demostró ser poco confiable para empaques con texto en múltiples direcciones.

Este enfoque, aunque más costoso en cómputo, fue validado por los casos de prueba: la imagen de Noxpirin (fondo azul oscuro, texto en múltiples orientaciones) era leída completamente invertida por el detector OSD, mientras que la evaluación por rotaciones cardinales identificó correctamente la orientación de mayor confianza. Los canales de color adicionales mejoraron la lectura de texto amarillo y rojo sobre fondos de color intenso. El aprendizaje es que para visión por computadora sobre empaques del mundo real, probar múltiples estrategias y seleccionar la de mayor confianza es más efectivo que intentar encontrar la estrategia óptima universal.

Acierto 4: Priorizar la amplitud del catálogo sobre la sofisticación del modelo

La decisión de utilizar el catálogo oficial completo del INVIMA (153.523 registros sanitarios) como base de datos del sistema, en lugar de construir un dataset propio reducido, demostró que para un MVP con impacto real la **calidad y amplitud de los datos supera a la complejidad del modelo**. El algoritmo KNN usado es conceptualmente simple, pero opera sobre un catálogo exhaustivo que cubre cualquier medicamento con registro colombiano vigente. El caso de Cefalexina ilustra esto: el sistema devolvió cinco alternativas farmacéuticamente distintas (tableta, cápsula, polvo para suspensión, gránulos, liberación prolongada) sin ajuste manual, gracias a la riqueza del catálogo.

El aprendizaje es que en sistemas de recomendación orientados a usuarios finales, la cobertura es un prerequisite más crítico que la precisión del ranking. Un sistema muy preciso sobre 100 medicamentos es menos útil que uno moderadamente preciso sobre 150.000.

Error 1: Subestimar la heterogeneidad del catálogo INVIMA

El catálogo del INVIMA registra el mismo principio activo de formas inconsistentes. “Cefalexina” aparece como “cefalexina”, “cefalexina base”, “cefalexina monohidrato”, “cefalexina monohidrato compactada”, “cefalexina monohidrato polvo liofilizado equivalente a cefalexina base anhidra”, entre otras variantes. Inicialmente, el sistema trataba estas cadenas como sustancias distintas y devolvía el mismo medicamento varias veces en las recomendaciones. Fue necesario implementar una deduplicación en dos capas: por nombre comercial normalizado y por perfil clínico (concentración numérica + forma farmacéutica), además de restricciones en el patrón de *matching* para la notación “X equivalente a Y mg de X base” del INVIMA.

El caso de prueba de Cefalexina validó que la deduplicación funciona correctamente: de decenas de registros con cefalexina en el catálogo, el sistema devolvió únicamente las cinco presentaciones farmacéuticas genuinamente distintas. El aprendizaje es que los datos gubernamentales del mundo real requieren un análisis exploratorio detallado antes de integrarlos en un sistema de recomendación: la limpieza y normalización de datos representó la mayor fuente de errores visibles para el usuario y la mayor parte del tiempo de corrección del sistema.

Error 2: Confundir confianza OCR con éxito de identificación

La confianza reportada por Tesseract mide la certeza del reconocimiento carácter a carácter, no la corrección semántica del texto extraído ni la capacidad del sistema para mapearlo a un medicamento real. Los casos de falla por ángulo oblicuo (Naproxeno Sódico y Omeprazol) ilustraron esto con claridad: ambos reportaron una confianza OCR del 95 %, pero el texto extraído no produjo ninguna coincidencia válida en el catálogo INVIMA porque la perspectiva deformada de la imagen había distorsionado la geometría del texto.

Este hallazgo motivó la incorporación del *match score* de catálogo como segunda métrica de confianza, mostrada en la interfaz junto con la confianza OCR. El aprendizaje es que en pipelines de OCR aplicado a dominios específicos, es necesario validar la calidad del texto extraído contra el conocimiento del dominio (en este caso, el catálogo) y no confiar únicamente en las métricas internas del motor de reconocimiento.

Error 3: No contemplar la diferencia entre imagen de galería e imagen de cámara

Durante el desarrollo inicial, el sistema se probó casi exclusivamente con imágenes subidas desde galería, donde la calidad y las condiciones de captura son controlables. Al integrar la funcionalidad de cámara en tiempo real, surgieron diferencias importantes: las imágenes de cámara tienen variaciones de iluminación, pueden estar desenfocadas, y la resolución depende del dispositivo. Los casos de falla por ángulo oblicuo (Naproxeno y Omeprazol) son representativos del comportamiento real del usuario cuando fotografía un medicamento sin instrucciones de captura explícitas.

El aprendizaje es que en aplicaciones móviles que dependen de visión por computadora, las pruebas deben realizarse desde el inicio con imágenes representativas del canal de entrada real (cámara del dispositivo), no solo con imágenes de referencia de alta calidad. El entorno de captura es parte del sistema, y diseñar guías visuales de encuadre en la interfaz (como las usadas en aplicaciones de escaneo de documentos) hubiera reducido esta categoría de fallas desde el diseño.

Error 4: Comportamiento no determinístico del LLM ante fallos de recuperación RAG

Los casos de prueba revelaron que el módulo LLM presenta dos modos de falla distintos ante una recuperación RAG incorrecta, y no existe garantía de cuál ocurrirá. En el Caso 4 (Doxiciclina), el modelo generó silenciosamente una explicación sobre *doxazosina* sin advertir al usuario, porque la similitud léxica superficial entre ambos términos era suficiente para que el contexto recuperado pareciera plausible. En el Caso 6 (Aspirina), ante una distancia semántica más evidente entre el principio activo solicitado y el contexto recuperado, el mismo modelo detectó la inconsistencia y emitió una advertencia explícita.

Esta variabilidad de comportamiento es problemática en un contexto clínico: el sistema no puede garantizar que los errores del LLM sean detectables por el usuario. El aprendizaje es que en pipelines RAG para aplicaciones críticas, no es suficiente confiar en la capacidad de auto-corrección del modelo; es necesario implementar validaciones explícitas en la capa de recuperación, como un umbral mínimo de similitud coseno que impida invocar al LLM cuando el contexto recuperado no es suficientemente relevante para el principio activo consultado.

9.2. Conclusiones y trabajo futuro

Conclusión 1: Viabilidad del pipeline OCR → verificación → KNN para el contexto colombiano

Los seis casos de prueba documentados en la sección de Evaluación demuestran que el pipeline implementado es viable como herramienta de apoyo en el contexto de la crisis de desabastecimiento de medicamentos en Colombia. En cuatro de los seis casos (Acetaminofén, Cefalexina, Doxíciclina, Aspirina), el sistema identificó correctamente el medicamento a partir de la imagen con confianza OCR del 99 % y produjo alternativas con equivalencia por principio activo en tiempo de respuesta inferior a 10 segundos. Las dos fallas documentadas (Naproxeno, Omeprazol) corresponden a condiciones de captura claramente inadecuadas (ángulos oblicuos con mano en el encuadre), y en ambas el sistema respondió de forma segura: presentó campos vacíos y guió al usuario hacia la entrada manual, permitiendo completar el flujo sin pérdida de funcionalidad.

La combinación de OCR con estrategias de preprocesamiento múltiple, búsqueda en cascada contra el catálogo INVIMA completo y verificación humana intermedia demostró ser un diseño **robusto ante sus propias limitaciones**: cuando algún componente falla, el sistema no produce recomendaciones incorrectas, sino que escala el control al usuario.

Conclusión 2: La calidad de las recomendaciones está acotada por la calidad del catálogo

El sistema de recomendación KNN es tan bueno como los datos sobre los que opera. La heterogeneidad en la nomenclatura de principios activos del catálogo INVIMA —que refleja la ausencia de un vocabulario controlado en los registros sanitarios colombianos— limita la precisión de las equivalencias. La deduplicación implementada resuelve el problema de duplicados visibles para el usuario, y los casos de prueba confirman su efectividad (Cefalexina: 5 alternativas únicas genuinamente distintas). Sin embargo, la raíz del problema persiste: el mismo principio activo con múltiples grafías en el catálogo obliga a reglas de normalización específicas que pueden fallar con variantes no contempladas.

Para que un sistema como MediFinder opere a escala con alta confiabilidad, sería necesario un proceso previo de estandarización de principios activos con respaldo farmacológico, por ejemplo basado en el sistema ATC de la OMS, que el catálogo INVIMA ya utiliza parcialmente para la clasificación terapéutica pero no para la nomenclatura de principios activos.

Conclusión 3: La CNN como fallback visual es promisorio pero requiere datos representativos

La integración de EfficientNet-B0 como respaldo visual para los casos en que el OCR falla es una extensión arquitectónica coherente con los trabajos relacionados revisados. En los casos de prueba, el módulo CNN se activó correctamente en las situaciones previstas (falla OCR por ángulo oblicuo). Sin embargo, en ambos casos tampoco logró identificar el medicamento, dado que el espacio de embeddings fue construido con imágenes de referencia frontales y controladas que no representan las condiciones de captura real del usuario.

La CNN actualmente tiene utilidad principalmente para los medicamentos cuyas imágenes frontales formaron parte del conjunto de construcción de embeddings (225 imágenes de referencia scrapeadas de Farmatodo y Cruz Verde). Para que este componente sea un mecanismo de respaldo real a escala nacional, se requeriría un dataset de imágenes de empaques colombianos fotografiados en condiciones de usuario final, lo cual constituye el trabajo de recolección de datos más relevante aún pendiente.

Conclusión 4: El módulo LLM requiere un umbral de relevancia RAG antes de generar explicaciones

Los casos de Doxyciclina y Aspirina evidenciaron que el módulo LLM puede producir explicaciones clínicamente incorrectas cuando la recuperación RAG no encuentra un documento suficientemente representativo del principio activo consultado. La variabilidad de comportamiento observada —falla silenciosa en un caso, auto-detección en otro— indica que la confiabilidad del módulo depende tanto de la cobertura de la *knowledge base* como de qué tan evidente sea la discrepancia semántica para el modelo.

En la versión actual, la *knowledge base* cubre 11.217 documentos de principios activos contruidos a partir de los CSV del INVIMA y Wikipedia, pero su cobertura es irregular: los antibióticos y medicamentos menos comunes tienen representación escasa o nula, lo que expone al sistema a recuperaciones incorrectas. La conclusión es que el módulo LLM no puede considerarse confiable sin un mecanismo de validación en la capa de recuperación que garantice que el contexto entregado al modelo corresponde al principio activo consultado.

Trabajo futuro

Las mejoras prioritarias identificadas a partir de los resultados de evaluación son las siguientes, ordenadas por impacto potencial:

Detección de calidad de imagen previa al OCR. Los casos de falla por ángulo oblicuo (Naproxeno, Omeprazol) sugieren incorporar una etapa de evaluación de calidad antes de ejecutar el pipeline: estimación del ángulo de inclinación del empaque, detección de objetos en el encuadre (manos, fondos de color) y porcentaje de área útil. Si la imagen no supera umbrales mínimos, el sistema solicitaría una nueva captura antes de procesar, evitando el ciclo innecesario OCR → CNN → falla → campos vacíos.

Umbral mínimo de similitud en la recuperación RAG. Para resolver los fallos del módulo LLM documentados en los Casos 4 y 6, se debe implementar un umbral de similitud coseno mínimo en la recuperación de contexto: si el documento más cercano en la *knowledge base* no supera ese umbral, el sistema informaría al usuario que no dispone de información verificada sobre ese principio activo en lugar de generar una explicación potencialmente incorrecta.

Ampliación del dataset de imágenes CNN. Para que el módulo visual sea un respaldo real, se requiere un conjunto de imágenes de empaques colombianos fotografiados en condiciones reales de usuario (ángulos variados, iluminación heterogénea, diferentes dispositivos). El proceso de *web scraping* implementado sobre Farmatodo y Cruz Verde provee una base de partida; escalarlo a más fuentes y complementarlo con capturas de usuarios voluntarios aumentaría significativamente la cobertura y la robustez del fallback CNN.

Integración de disponibilidad geográfica en tiempo real. La mejora con mayor impacto para el usuario final sería integrar la API de *Medicamentos a un Clic* del Ministerio de Salud y Protección Social para incorporar disponibilidad por municipio o departamento. Actualmente, MediFinder indica *qué* medicamentos son equivalentes, pero no *dónde* conseguirlos. Enlazar cada alternativa recomendada con datos de disponibilidad regional transformaría el sistema de una herramienta informativa a una herramienta operativa, que es lo que el paciente realmente necesita durante la crisis de desabastecimiento.

Referencias

- Acemi. (2025, agosto). *Evolución del gasto privado en medicamentos en Colombia 2021–2025 (I Trim): Salud en cifras edición 7*. <https://acemi.org.co/evolucion-del-gasto-privado-en-medicamentos-en-colombia-2021-2025-i-trim-salud-en-cifras-edicion-7/> (Consultado el 17 de febrero de 2026, desde).
- Arias, J. (2021, febrero). *¿Cuál es la diferencia entre una IPS y una EPS?* Alcaldía de Bogotá. <https://bogota.gov.co/mi-ciudad/salud/cual-es-la-diferencia-entre-una-ips-y-una-eps> (Consultado el 17 de febrero de 2026, desde).
- Calero, C. (2025, septiembre). *El precio de la salud: los medicamentos más costosos para el gasto público en Colombia*. Cambio. <https://cambiocolombia.com/economia/articulo/2025/9/el-precio-de-la-salud-los-medicamentos-mas-costosos-para-el-gasto-publico-en/> (Consultado el 17 de febrero de 2026, desde).
- Colprensa. (2025, septiembre). *Falta de medicamentos agudiza crisis de salud en Colombia*. El Universal. <https://www.eluniversal.com.co/colombia/2025/09/26/falta-de-medicamentos-agudiza-crisis-de-salud-en-colombia/> (Consultado el 17 de febrero de 2026, desde).
- Díaz, E. A. (2025, junio). *Crisis de medicamentos en Colombia, muchas causas y el más afectado es el paciente*. Revista Pesquisa Javeriana. <https://www.javeriana.edu.co/pesquisa/porque-de-la-crisis-de-medicamentos/> (Consultado el 17 de febrero de 2026, desde).
- IBM. (2025, noviembre). *Redes neuronales convolucionales*. <https://www.ibm.com/es-es/think/topics/convolutional-neural-networks> (Consultado el 17 de febrero de 2026, desde).
- Instituto Nacional de Vigilancia de Medicamentos y Alimentos (INVIMA). (2026). *Listado de registros sanitarios de medicamentos*. INVIMA. <https://www.invima.gov.co/biblioteca/listado-registros-sanitarios-medicamentos-invima> (Consultado el 5 de abril de 2026, desde).
- Kavlakoglu, E. (2025, noviembre). *KNN*. IBM. <https://www.ibm.com/mx-es/think/topics/knn> (Consultado el 17 de febrero de 2026, desde).

Ministerio de Salud y Protección Social de Colombia. (2025, julio). *La deuda acumulada de las EPS que asciende a 32 billones de pesos, evidencia el colapso del modelo actual de intermediación*. <https://www.minsalud.gov.co/CC/Noticias/2025/Paginas/deuda-acumulada-de-EPS-asciende-a-32-billones-de-pesos.aspx> (Consultado el 17 de febrero de 2026, desde).

Ministerio de Salud y Protección Social de Colombia. (2026). *Medicamentos a un Clic*. Min-Salud Colombia. <https://medicamentosau clic.gov.co/> (Consultado el 5 de abril de 2026, desde).

Saavedra, F. (2025, septiembre). *Crisis por escasez de medicamentos básicos en hospitales: Gobierno anunció medidas para abastecimiento en UCI*. Infobae. <https://www.infobae.com/colombia/2025/09/03/gobierno-responde-a-crisis-de-medicamentos-criticos-en-hospitales-y-anuncio-medidas-para-abastecimiento-en-uci/> (Consultado el 17 de febrero de 2026, desde).